데이터과학 파이썬

심송용(한림대학교 데이터과학스쿨)

http://jupiter.hallym.ac.kr

numpy 패키지

일양분포(uniform distribution)

일양분포 $U(0,1)$에서의 난수발생으로 [0, 1) 구간(0포함, 1미포함)에서의 난수를 발생시킨다. 사용법은

```
numpy.random.random(size=None)
```

으로 size에 설정한 개수만큼의 난수를 얻는다. size가 설정되지 않으면 1개 발생한다.

```
y = np.random.random(size=1000)
print('mean:', statistics.mean(y))
print('variance:', statistics.variance(y))
```

```
mean: 0.5079961752832307
variance: 0.08079913015252346
```

$X \sim U(0,1)$ 이면 $f(x) = 1,\ 0 < x < 1$ 이므로 $E(X) = \int_0^1 x \cdot 1dx = 1/2$,

$Var(X) = E(X^2) - E(X)^2 = 1/3 - 1/4 = 1/12 = 0.83$이므로 이 모의실험을 계속하면 기댓값과 분산이 이 두 값에 가까운 값을 얻음.

numpy 패키지

정규분포(normal distribution)

표준정규분포 난수를 $(n+1)$ 차원의 ndarray로 얻으려면 randn을 다음과 같이 사용한다.

```
numpy.random.randn(d0, d1, ..., dn)
```

이 함수의 결과는 표준정규분포에 생성한 난수를 d0 ×d1×⋯×dn 차원의 ndarray에 저장한 결과를 얻는다.

```
x = np.random.randn(2,10)
print(x)
[[ 1.60303222  0.28137692  0.72921162  1.68364504  1.36953885 -1.59955219
  -1.55665477 -0.89193831  0.97541333  0.59156993]
 [-1.24650592 -0.8027508  -0.67566298 -0.50741227 -0.01844948 -0.00889509
  -1.2611688  -1.34391655  1.27698134  0.70807809]]
```

로 2행, 10열인 ndarray의 원소를 표준정규분포의 난수로 얻음.

평균과 표준편차가 각각 loc와 scale인 정규분포에서 size 개수만큼의 난수를 얻으려면 normal 함수를 사용한다. 정규분포에서 평균 μ와 표준편차 σ는 각각 location 및 scale

numpy 패키지

parameter라고도 불린다. scale에 분산이 아닌 표준편차가 설정됨에 주의한다.

```
numpy.random.normal(loc=0.0, scale=1.0, size=None)
```

```
y = np.random.normal(size=1000)
print('mean:', statistics.mean(y))
print('variance:', statistics.variance(y))
```

mean: -0.01297967791228822

variance: 0.9787245424554448

로 이론적인 기댓값 0과 분산 1에 근접하는 값을 얻음.

위의 모의실험에서 난수의 생성에서 size의 값을 올리면 이론적인 μ, σ^2에 더 가까운 값을 얻는 것을 확인할 수 있으며, 표본의 개수가 크면 좀더 정확한 추정이 이루어질 수 있음을 간접적으로 확인함.

numpy 패키지

이외에도

- binomial(n, p[, size]): 이항분포 $B(n,p)$에서 size개의 난수 발생.
- poisson([lam, size]): 포아송분포 $Poi(\lambda)$에서 size개의 난수 발생.
- chisquare(df[, size]): 자유도 df인 카이제곱분포 size개의 난수 발생.
- exponential([scale, size]): 지수분포 $\exp(\lambda)$에서 size개의 난수 발생.
- f(dfnum, dfden[, size]): $F_{dfnum,\,dfden}$ 분포에서 size개의 난수 발생.
- standard_t(df[, size]): 자유도 df인 t-분포에서 size개의 난수 발생.

등 많은 통계 분포에서 난수를 얻을 수 있다.

Lab: 단순회귀분석 모형

단순회귀분석 모형은 주어진 x에서 y의 값이 오차를 포함한 선형관계

$$y = \beta_0 + \beta_1 x + \epsilon,\ \ \epsilon \sim N(0,\sigma^2)$$

인 모형을 말한다. 이 모형에서 β_0와 β_1을 추정하기 위해 n개의 짝 $(x_1,y_1),(x_2,y_2),\ldots,(x_n,y_n)$를 얻으면

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i,\ \ \epsilon_i \sim N(0,\sigma^2)\text{이고 독립 } i = 1,2,\ldots,n$$

numpy 패키지

인 관계식을 얻을 수 있으며 이 때 회귀계수의 추정치는

$$\hat{\beta}_1 = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2}, \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

임이 알려져 있다. x의 값이 1, 2, … ,30일 때 $y = 2 + 3x + \epsilon$인 모형의 자료를 모의실험으로 얻고 회귀계수를 계산해보자. 오차항의 표준편차는 10으로 한다.

```
# numpytest3.py

import numpy as np
import statistics
import matplotlib.pyplot as plt

x = np.linspace(1, 30, 30, endpoint = True)  # 1부터 30까지 정수
n = len(x)                                   # 자료크기=30
y = 2+3*x + np.random.normal(size=n, loc=0, scale=10) # 모형식 난수 적용
mx = statistics.mean(x);  my = statistics.mean(y)   # 평균계산
```

numpy 패키지

```
b1 = (sum(x*y) - n* mx * my ) / (sum(x ** 2) - n* mx **2)
# ndarray라 쉽게 공식대로 적용하여 반복문없이 b1 계산
b0 = my - b1 * mx  # b0 계산
yhat = b0 + b1 * x  # b0, b1에 의해 y의 예측값 계산

b0 = round(b0, 3); b1 = round(b1, 3)  # 출력편의를 위해 반올림

print('회귀식은 : y= {0} + {1} x 입니다.'.format(b0, b1))

plt.plot(x, y, '*')      # 원자료 산점도
plt.plot(x, yhat)        # 예측값에 의한 직선
plt.text(20, 35,s='y= {0} + {1} x'.format(b0, b1) )  # 회귀식문자열
plt.xlim(-0.5, 30.5)    # 그림에서 x 축의 범위 설정
```

numpy 패키지

출력

회귀식은 : y= 5.464 + 2.712 x 입니다.

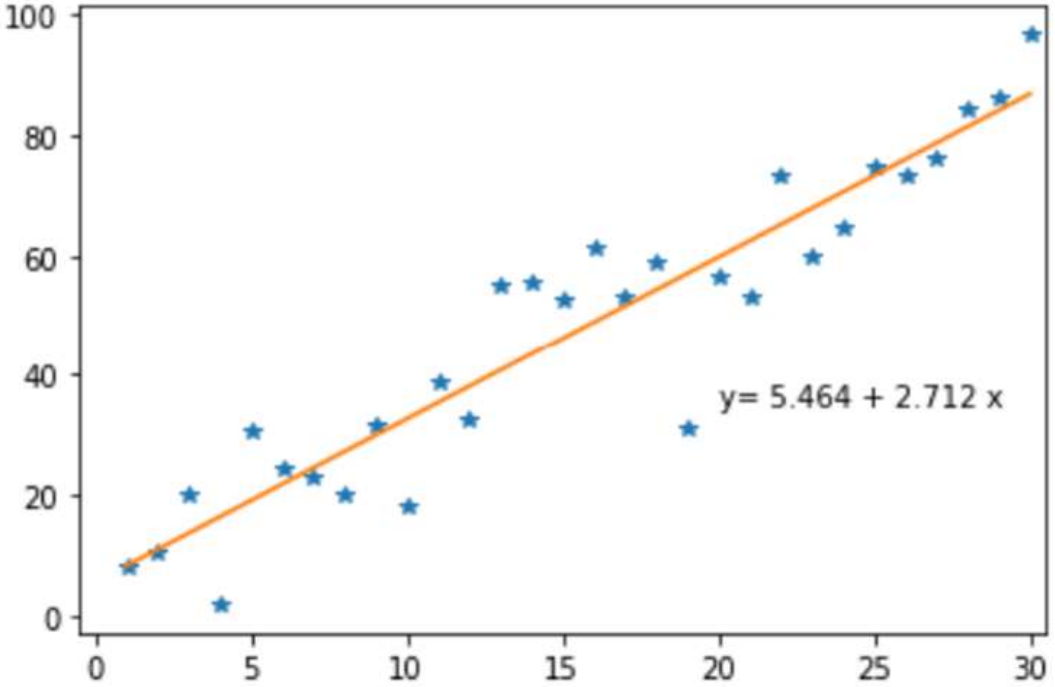

오차항에 난수가 있으므로 y 값이 계속 달라지므로 회귀식 및 그림은 그때그때 다름.