데이터과학 파이썬

심송용(한림대학교 데이터과학스쿨)

http://jupiter.hallym.ac.kr

pandas 패키지

pandas는 데이터 처리(manipulation)과 분석을 위해 파이썬에서 사용할 수 있는 빠르면서도 강력한 모듈이다. pandas는 다음과 같은 로고를 사용한다.

pandas는 자료를 처리하기 위해 사용하는 데이터 프레임(data frame) 기능을 가지고 있으며 일차원인 경우 series를 사용할 수도 있다. 보통 pandas를 사용하기 위해 pd라는 이름으로 다음

```
import pandas as pd
```

와 같이 사용하므로 이하 pd는 pandas를 의미한다.

pandas 패키지

데이터 프레임 만들기

데이터 프레임은 2차원 구조로 열은 변수를, 행은 케이스(case)를 구성하는 자료의 형태이다. pandas 데이터 프레임의 생성은 자료를 직접 입력하여 만들 수 있다. 이때 값이 리스트 등인 경우 리스트와 같은 구조로 자료가 입력된다. 사용하는 클래스는 DataFrame으로

```
class pandas.DataFrame(data=None, index=None, columns=None, ...)
```

로 사용한다. data에는 데이터 프레임의 자료, index와 columns에는 행이름과 열이름에 사용할 값을 설정한다. # pandastest2.py

```
import pandas as pd

mylist1 = [1, 2, 5, 0, 0]
df1 = pd.DataFrame(mylist1)
print(df1)
   0
0  1
```

pandas 패키지

```
1  2
2  5
3  0
4  0
```

⇨ **1차원 리스트는 1개의 변수를 가진 데이터 프레임**

```
df2 = pd.DataFrame([ [1, 'a', 1.23, True],
    [4, 'column', 23.5, False],
    [8, 'with',  45.6, True],
    [7, 'a',  32.1234, False],
    [9, 'string', 89.4530, True]], columns=['var0', 'var1','var2', 'var3'])
print(df2)
   var0     var1      var2   var3
0     1        a    1.2300   True
1     4   column   23.5000  False
2     8     with   45.6000   True
3     7        a   32.1234  False
4     9   string   89.4530   True
```

⇨ **2차원 리스트는 각 행이 하나의 케이스(행)**

pandas 패키지

```
df3 = pd.DataFrame({
    "var1": [1, 4, 8, 7, 9],
    "var2": ['a', 'column', 'with', 'a', 'string'],
    "var3": [1.23, 23.5, 45.6, 32.1234, 89.453],
    "var4": [True, False, True, False, True]},
    index=['case1', 'case2','case3','case4','case5'])
print(df3)
```

	var1	var2	var3	var4
case1	1	a	1.2300	True
case2	4	column	23.5000	False
case3	8	with	45.6000	True
case4	7	a	32.1234	False
case5	9	string	89.4530	True

⇨ 딕셔너리는 각 키(key) 하나의 변수(열)을 구성)

pandas 패키지

인덱싱

데이터 프레임의 인덱싱은 iloc 속성을 사용한다. DataFrame.iloc[i,j]는 (i,j) 번째 인덱스의 값을 가져온다. 모든 행 또는 열은 :를 사용하고 범위는 start:end를 사용(end 미포함)한다.

print(df3.iloc[0,2]) ⇨ (0,2) 위치의 값

1.23

print(df3.iloc[2,:]) ⇨ 2번 행(3번째 행)

```
var1        8
var2     with
var3     45.6
var4     True
```

print(df3.iloc[:,2]) ⇨ 2번 열(3번째 열)

```
Name: case3, dtype: object
case1      1.2300
case2     23.5000
```

pandas 패키지

```
case3     45.6000
case4     32.1234
case5     89.4530
```

print(df3.iloc[0:2,2]) ⇨ 2번 열(3번째 열)의 행번호 0, 1(2 미포함)

```
Name: var3, dtype: float64
case1      1.23
case2     23.50
Name: var3, dtype: float64
```

특정한 변수의 열을 가져올 때는 iloc 속성을 사용하지 않고 데이터 프레임에서 변수(열) 이름을 설정하거나 변수 이름을 데이터 프레임의 속성으로 사용한다.

print(df3['var2'])

```
case1          a
case2     column
case3       with
```

pandas 패키지

case4 a

case5 string

Name: var2, dtype: object

print(df3.var2) ⇨ 위와 동일한 결과

csv 파일 처리

read_csv 메소드

pandas의 read_csv 메소드는 CSV(comma separated values; 콤마를 구분자로 사용) 파일을 읽는데 사용하는 메소드이다. 하지만 구분자를 따로 설정할 수 있으므로 텍스트 파일을 읽는데 사용한다고 보아야 한다.

```
pandas.read_csv(filepath_or_buffer, sep=',', header='infer', names=None,
        skiprows=None, skipfooter=0, skip_blank_lines=True,
        thousands=None, decimal='.', lineterminator=None, quotechar='"',
        comment=None, encoding=None, index_col...)
```

- filepath_or_buffer: 읽을 파일의 경로
- sep: 구분자로 사용한 문자. 둘 이상의 빈칸은 '\s+'로 설정한다.

pandas 패키지

- header: 자료내에 각 열의 이름이 있을 때 열 이름이 있는 행번호를 설정한다. 첫 줄이 변수이름이면 0을 설정하면 되고 파일 내에 변수이름이 없으면 None을 설정한다.
- names: 읽은 파일에서 각 열의 이름을 설정한다.
- skiprows, skipfooter: 파일의 첫부분 또는 끝부분에서 읽지 않을 줄의 수를 설정한다.
- thousand: 천 단위 구분에 사용한 문자를 설정한다. (대부분 없거나 콤마이나 일부 유럽 국가에서 소숫점에 콤마를 천단위 구분에 마침표를 사용하는 곳이 있음)
- decimal: 소숫점에 사용할 문자
- comment: 주석에서 사용한 문자. 해당 라인의 첫 줄이 comment에 설정한 문자이면 그 줄은 읽지 않음.
- encoding: 읽을 파일의 인코딩을 설정한다. 최근의 표준은 'utf-8'이나 윈도우나 오래전의 한글 인코딩으로 'cp949' 및 'euc-kr'를 사용하였다.
- 행의 이름으로 사용할 값이 저장된 열의 번호를 설정한다. 기본값은 None이다.

```
# pandastest1.py

import pandas as pd
```

pandas 패키지

```
mydf1 = pd.read_csv(r'D:\HWP\강의자료\파이썬\codes\bmi.txt',
    names=['ht', 'wt', 'year', 'religion', 'gender', 'marriage'],
                    header=None, sep='\s+')
print('Read from local: ', mydf1.shape)  ⇨ Read from local:  (177, 6)

url = "http://jupiter.hallym.ac.kr/ftpdata/data/bmi.txt"
mydf1 = pd.read_csv(url, names=['ht', 'wt', 'year', 'religion', 'gender', 'marriage'],
                    header=None, sep='\s+')
print('Read from web: ', mydf1.shape)  ⇨ Read from web:  (177, 6)
print(mydf1.head())
```

	ht	wt	year	religion	gender	marriage
0	167	68	1974	No	F	N
1	162	49	1974	C2	F	N
2	158	50	1978	C2	F	N
3	165	56	1977	No	F	N
4	160	52	1959	No	F	N

pandas 패키지

```
print(mydf1.tail())
      ht   wt   year  religion  gender  marriage
172  164   50   1982        No       F         N
173  163   52   1979        No       F         Y
174  160   56   1979        C2       F         N
175  160   49   1974        No       F         N
176  166   54   1980        No       F         N
print(mydf1.describe())
count   177.000000   177.000000   177.000000
mean    162.096045    53.468927  1971.819209
std       5.472746     7.174798     6.565325
min     150.000000    40.000000  1949.000000
   ⋮
```

to_csv 메소드

pandas 패키지

데이터 프레임의 내용을 CSV 형식(구분자를 다르게 하면 일반 텍스트) 형식의 파일로 저장하는 메소드이다. 사용법은

```
DataFrame.to_csv(path_or_buf=None, sep=',', na_rep='', float_format=None,
        columns=None, header=True, index=True, index_label=None,
        mode='w', encoding=None, decimal='.', errors='strict')
```

- path_or_buf: 저장할 파일의 이름(str) 또는 파일 핸들(file handle)을 설정한다. 기본값은 None인데 이 경우 데이터 프레임의 내용이 문자열로 반환된다.
- sep: 값을 구분할 구분자로 사용할 문자.
- na_rep: 결측값으로 사용할 문자열을 설정한다.
- header: 변수이름으로 사용할 문자열을 주거나 논리값을 설정한다. True가 기본값이며 데이터 프레임의 열이름이 첫줄에 포함된다.
- index: 행의 이름을 파일에 쓸지 설정한다. 기본값은 True이며 행이름이 따로 없는 경우 인덱스가 사용된다.
- mode: 파이썬의 파일 모드. 기본값은 'w'로 write 이다.
- encoding: 저장할 파일의 인코딩으로 기본값은 'utf-8'이다.

위에서 저장된 mydf1 데이터 프레임을 CSV 형식으로 저장해보자.

pandas 패키지

mydf1.to_csv(r'D:\HWP\강의자료\파이썬\codes\bmi.csv')

결과는 다음과 같다. 텍스트 편집기와 엑셀로 연 파일이며 index=False를 설정하면 행번호(인덱스, 행이름)는 출력되지 않는다.

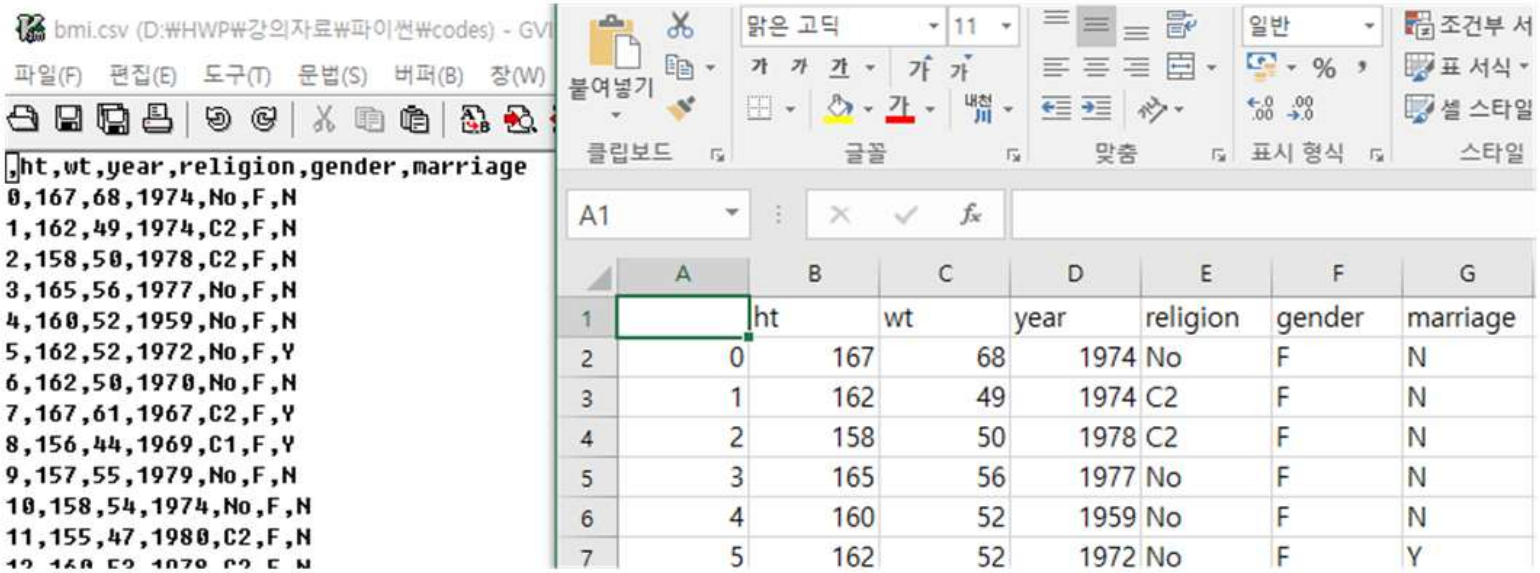

pandas 패키지

참고: 파일 탐색기 구동

대화형으로 프로그램이 구동되는 경우 파일이름을 프로그램에 직접 입력하지 않고 파일 탐색기를 열어 탐색기에서 파일을 지정하도록 할 수 있다. 아래는 encoding이 euc-kr인 score-euc.csv 를 읽을 예정이며 이 프로그램에서 encoding과 header 설정만 읽을 파일에 맞게 변경해주면 다른 파일도 정확하게 읽을 수 있다.

```
from tkinter import filedialog, Tk

root = Tk()  # Toolkit을 초기화
#mydf2 = pd.read_csv(filedialog.askopenfilename(parent=root),
                     header=0, encoding='cp949')
mydf2 = pd.read_csv(filedialog.askopenfilename(parent=root),
                     header=0, encoding='euc-kr')
root.withdraw()  # Toolkit  닫음
```

pandas 패키지

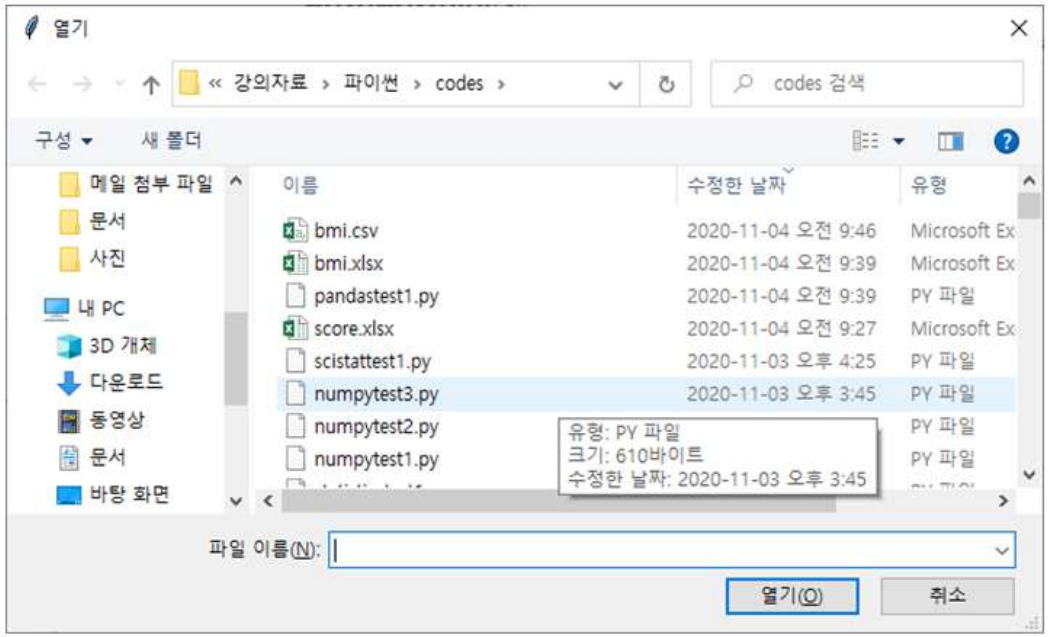


```
print("opened by file dialog: ", mydf2.shape)
print(mydf2.head())
print(mydf2.tail())
print(mydf2.describe())
```

⇨ opened by file dialog: (50, 7)

pandas 패키지

	name	korean	english	math	ns	ss	total
1	강대성	67	87	60	85	80	379
2	한준호	63	73	82	73	85	376
3	김종욱	74	53	76	72	58	333
4	박상호	55	65	49	84	96	349
5	김소현	76	69	69	92	70	376

	name	korean	english	math	ns	ss	total
46	김성홍	50	77	74	83	80	364
47	정미경	84	82	60	61	70	357
48	최수진	76	86	79	73	77	391
49	정지영	71	70	40	91	85	357
50	강민호	56	86	58	70	83	353

	korean	english	math	ns	ss	total
count	50.000000	50.000000	50.000000	50.000000	50.000000	50.000000
mean	67.520000	75.360000	65.740000	79.860000	75.480000	363.960000

⋮

pandas 패키지

참고:

- 위 프로그램에서 파일탐색기에서 취소 버튼을 클릭하였을 때 해야 할 작업이 정해지지 않아서 취소 버튼 클릭시 강제 종료가 필요.
- 파일로 저장하기 위해 탐색기를 열 때는 filedialog.askopenfilename 대신 filedialog.asksaveasfilename 메소드를 사용.