데이터과학 파이썬

심송용(한림대학교 데이터과학스쿨)

http://jupiter.hallym.ac.kr

pandas 패키지

엑셀 파일 처리

read_excel 메소드

```
pandas.read_excel(io, sheet_name=0, header=0, names=None, index_col=None,
                  skiprows=None, nrows=None, thousands=None,
                  comment=None, skipfooter=0, ...)
```

- io: 읽을 엑셀 파일의 경로를 설정한다. URL도 가능하며 로컬 파일을 URL로 설정하는 경우 file://localhost/path/to/table.xlsx 로 설정한다.
- sheet_name: 읽을 시트의 이름인 문자열 str, 시트 번호인 int, 또는 이들의 리스트(list) 등을 설정한다. [0, 1, "Sheet5"]와 같이 리스트로 설정한 경우 각각 첫 번째, 두 번째 및 시트 이름이 Sheet5인 시트를 읽어서 DataFrame의 딕셔너리를 만든다. None을 설정하면 모든 시트를 읽는다.
- header, names, index_col, skiprows, nrows, thousands, comment, skipfooter: read_csv 와 같음.

pandas 패키지

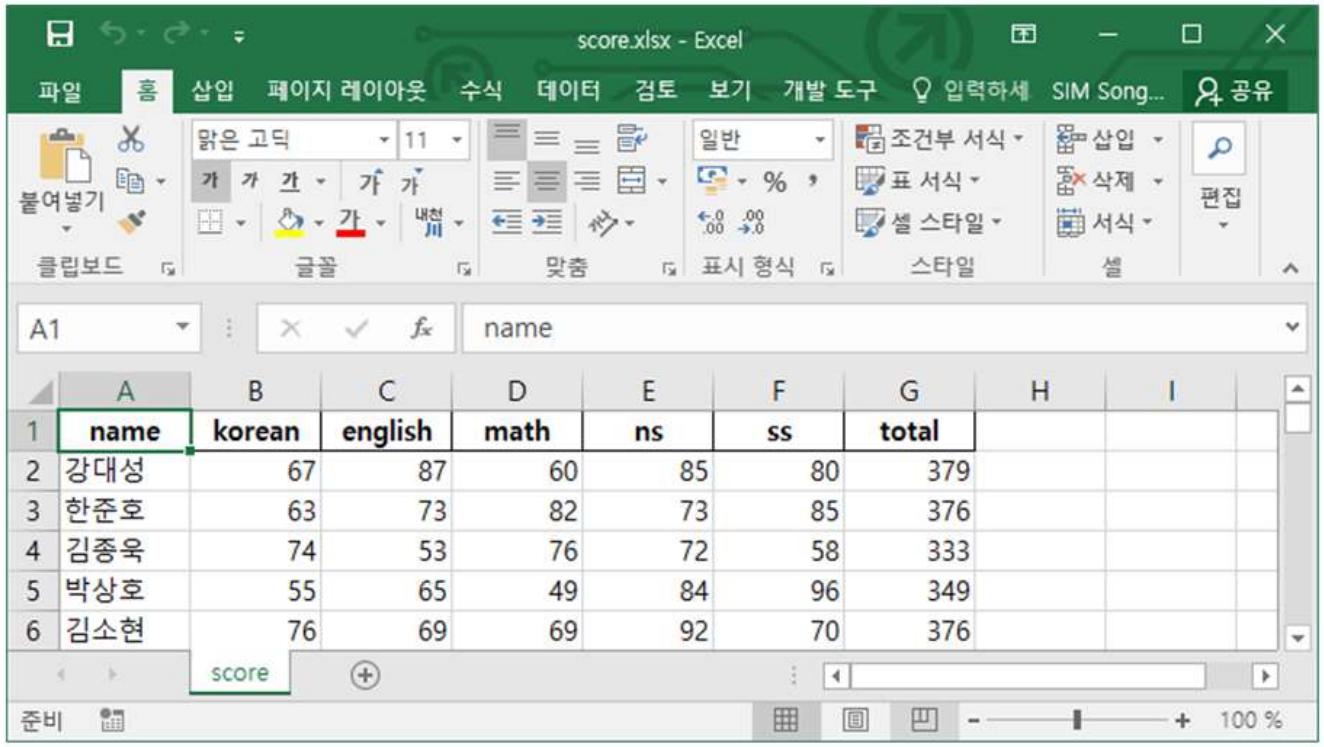

	A	B	C	D	E	F	G
1	name	korean	english	math	ns	ss	total
2	강대성	67	87	60	85	80	379
3	한준호	63	73	82	73	85	376
4	김종욱	74	53	76	72	58	333
5	박상호	55	65	49	84	96	349
6	김소현	76	69	69	92	70	376

```
mydf3 = pd.read_excel(r'D:\HWP\강의자료\파이썬\codes\score.xlsx',
        sheet_name='score')
print('Read from local excel file: ', mydf3.shape)
```

Read from local excel file: (50, 7)

pandas 패키지

to_excel 메소드

```
DataFrame.to_excel(excel_writer, sheet_name='Sheet1', na_rep='',
        float_format=None, columns=None, header=True, index=True,
        startrow=0, startcol=0, encoding=None, inf_rep='inf', ...)
```

- excel_writer: 저장할 엑셀 파일의 이름 또는 ExcelWriter 개체
- sheet_name: 저장할 시트의 이름.
- na_rep: 결측치의 표시로 사용할 문자열.
- float_format: 실수의 저장 포맷을 설정한다. 예를 들어 float_format="%.2f" 소숫점 이하 2자리를 사용하여 0.1234 는 0.12로 저장
- header, index, encoding, encoding: read_excel 참고
- startrow, startcol: 쓰기 시작할 행과 열번호
- inf_rep: 무한대 표시 문자열. 기본값 'inf'
- index: 인덱스(또는 행이름)를 출력할지 설정. 기본값 True.

pandas 패키지

```
mydf1.to_excel(r'D:\HWP\강의자료\파이썬\codes\bmi.xlsx',
                sheet_name='bmi', index=False)
```

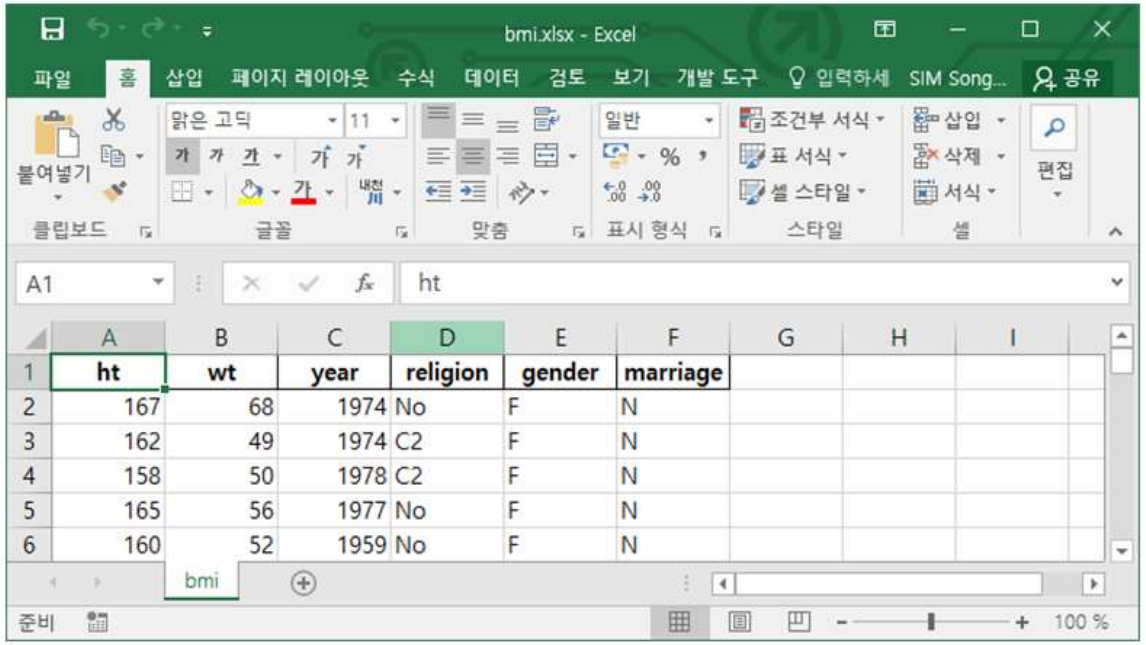

ht	wt	year	religion	gender	marriage
167	68	1974	No	F	N
162	49	1974	C2	F	N
158	50	1978	C2	F	N
165	56	1977	No	F	N
160	52	1959	No	F	N

pandas 패키지

데이터 프레임 그룹핑/필터링

```
mydfG = mydf1.groupby('gender')
print(mydfG.get_group('M'))
```

	ht	wt	year	religion	gender	marriage
19	172	72	1974	No	M	N
23	168	52	1972	Bu	M	N
39	170	70	1971	No	M	N
79	176	73	1954	Bu	M	Y
84	160	62	1972	No	M	N

⋮

```
mydfM = mydf1[ mydf1['gender']=='M']
print(mydfM)
```

위와 동일한 결과

pandas 패키지

```
print(mydf1[ mydf1['ht'] > 175] )
```

	ht	wt	year	religion	gender	marriage
79	176	73	1954	Bu	M	Y
120	180	80	1960	C2	M	Y
164	179	59	1974	C1	M	N
169	178	60	1965	No	M	Y

- df.describe(): 기술통계량 계산
- df.mean() 평균 계산
- df.corr() 상관계수 계산
- df.count() 각 변수의 자료수(non-null)
- df.max() 최댓값 계산
- df.min() 최솟값 계산
- df.median() 중앙값 계산
- df.std() 표준편차 계산

pandas 패키지

```
print(mydf1.describe())
```

	ht	wt	year
count	177.000000	177.000000	177.000000
mean	162.096045	53.468927	1971.819209
std	5.472746	7.174798	6.565325
min	150.000000	40.000000	1949.000000
25%	158.000000	49.000000	1970.000000
50%	162.000000	52.000000	1973.000000
75%	165.000000	57.000000	1976.000000
max	180.000000	80.000000	1982.000000

```
print(mydf1.corr())
```

	ht	wt	year
ht	1.000000	0.647398	-0.087437
wt	0.647398	1.000000	-0.298173
year	-0.087437	-0.298173	1.000000

pandas 패키지

변수의 추가 및 삭제

변수(열)의 추가는 df['new_col']=values(또는 variable)로 할 수 있고 삭제는 파이썬 기본 명령 del을 사용하여 del df['col_to_del']로 실행한다. 앞의 데이터 프레임 mydf1의 키와 몸무게 자료에서 체질량지수를 계산하여 mydf1에 추가해보자. 체질량지수(Body Mass Index; BMI)는 몸무게(kg)을 키(m)의 제곱으로 나눈 값이다.

```
qidx = mydf1.wt / (mydf1.ht/100) ** 2
mydf1['bmi'] = qidx
print(mydf1.head())
```

	ht	wt	year	religion	gender	marriage	bmi
0	167	68	1974	No	F	N	24.382373
1	162	49	1974	C2	F	N	18.670934
2	158	50	1978	C2	F	N	20.028842
3	165	56	1977	No	F	N	20.569330
4	160	52	1959	No	F	N	20.312500

pandas 패키지

열의 삭제는 del 명령으로

```
del mydf1['bmi']
print(mydf1.head())
```

	ht	wt	year	religion	gender	marriage
0	167	68	1974	No	F	N
1	162	49	1974	C2	F	N
2	158	50	1978	C2	F	N
3	165	56	1977	No	F	N
4	160	52	1959	No	F	N

특정한 위치에 변수를 추가하고자 할 때는 DataFrame.insert 메소드를 사용할 수 있다.

```
DataFrame.insert(loc, column, value, allow_duplicates=False)
```

loc는 자료가 들어갈 위치(0에서 시작), column에는 변수(열) 이름, value에는 변수의 값, allow_duplicate는 열이름 중복 허용여부를 설정한다.

pandas 패키지

```
mydf1.insert(2, 'bmi', qidx)
print(mydf1.head())
```

	ht	wt	bmi	year	religion	gender	marriage
0	167	68	24.382373	1974	No	F	N
1	162	49	18.670934	1974	C2	F	N
2	158	50	20.028842	1978	C2	F	N
3	165	56	20.569330	1977	No	F	N
4	160	52	20.312500	1959	No	F	N

관련메소드:

DataFrame.append(other, ignore_index=False, verify_integrity=False, sort=False) ⇨ 행 추가

DataFrame.drop(labels=None, axis=0, index=None, columns=None, level=None, inplace=False, errors='raise') ⇨ 행 또는 열의 삭제

DataFrame.add(other, axis='columns', level=None, fill_value=None)
⇨ 행 또는 열의 추가

수고하셨습니다^^